ESALO

BIG DATA E DEPLOYMENT DE MODELOS

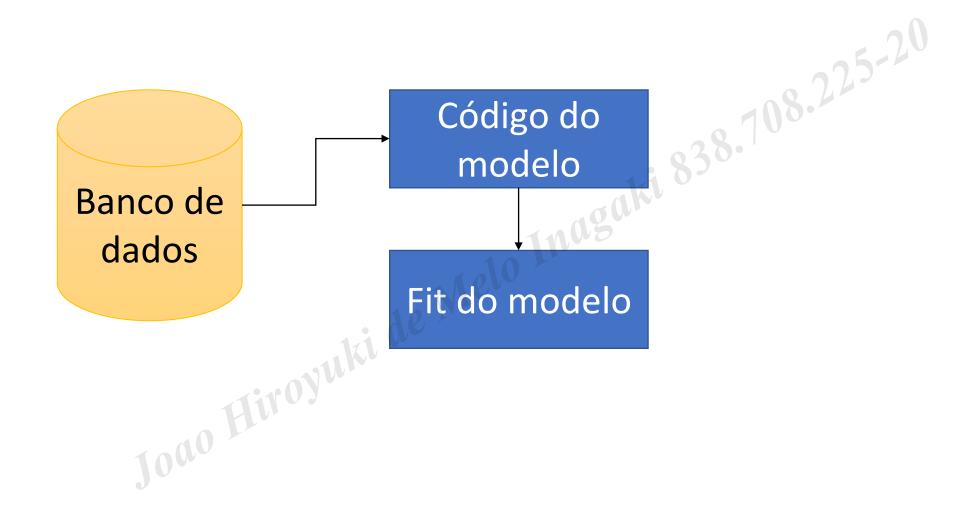
Helder Prado Santos

*A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados, é do professor.

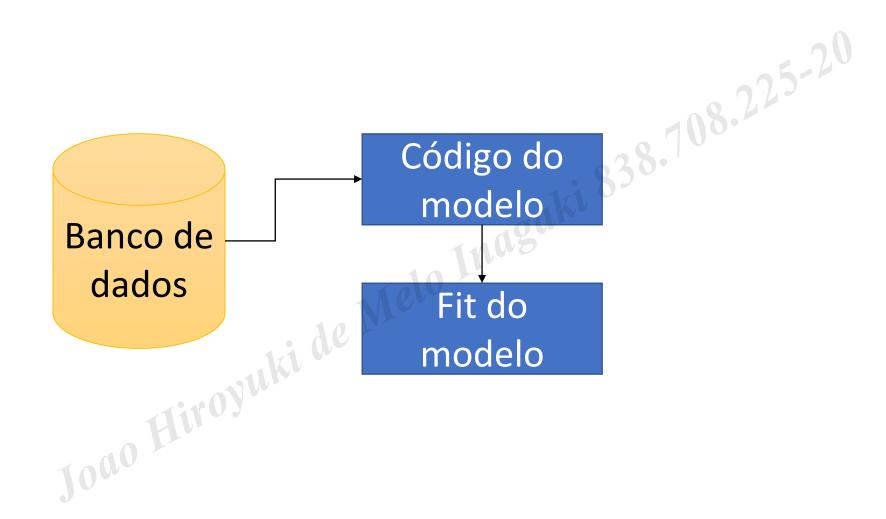
Proibida a reprodução total ou parcial, sem autorização. Lei nº 9610/98



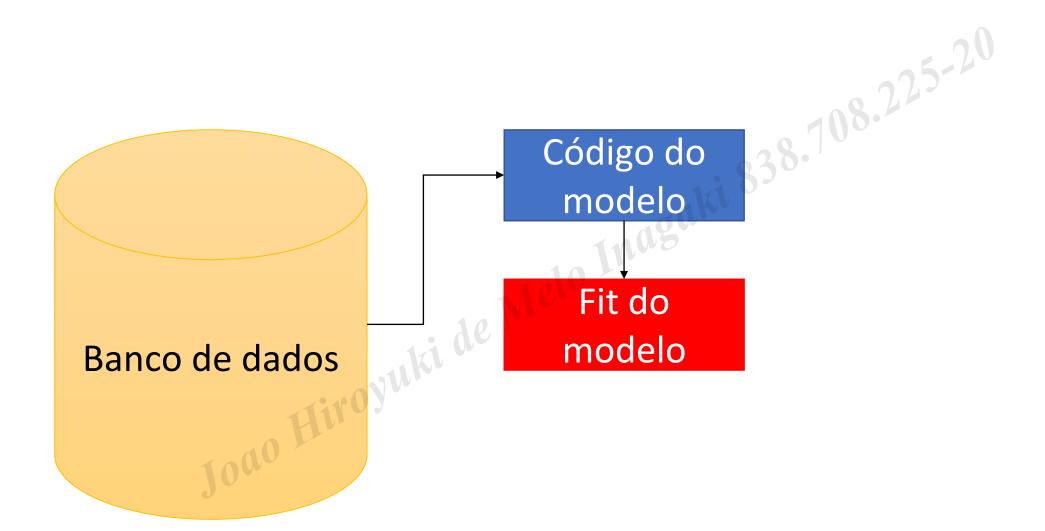
Vamos desenvolver um modelo



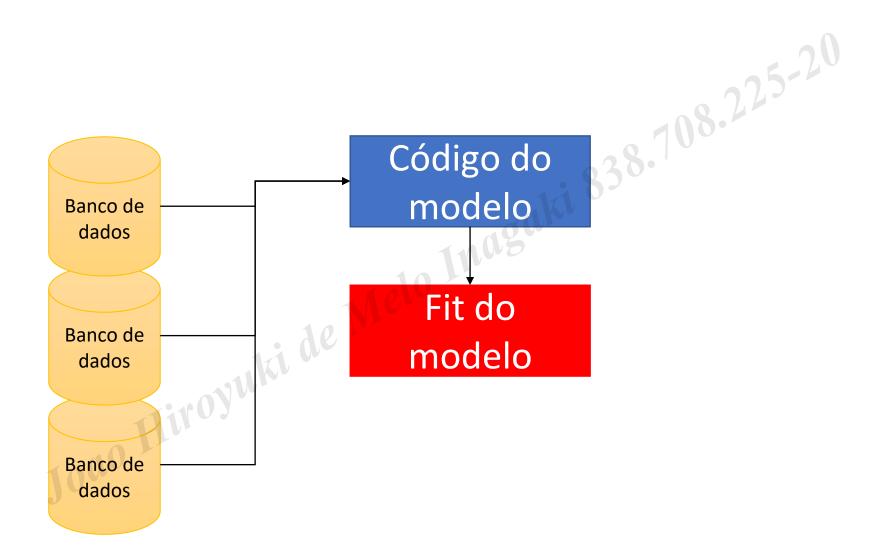




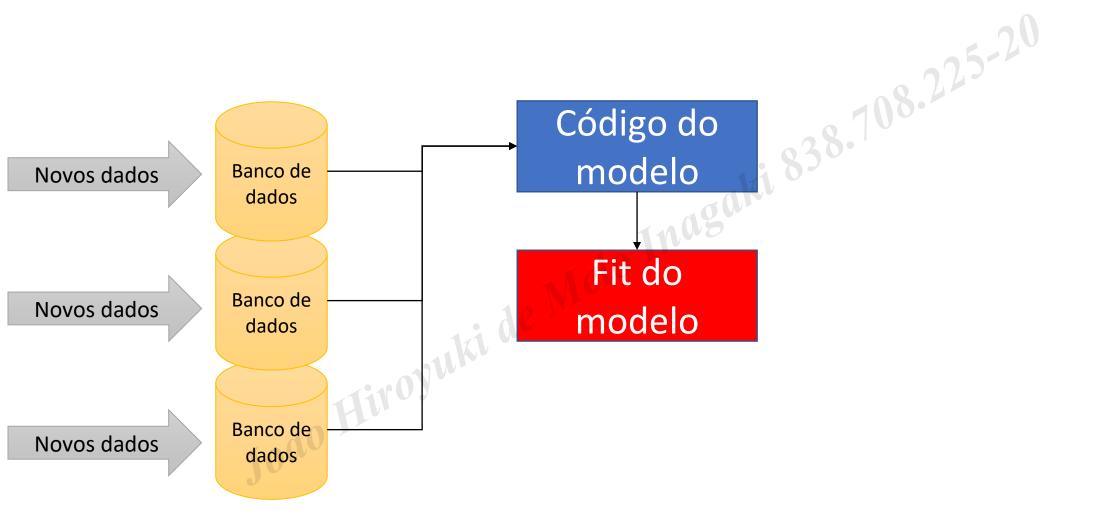












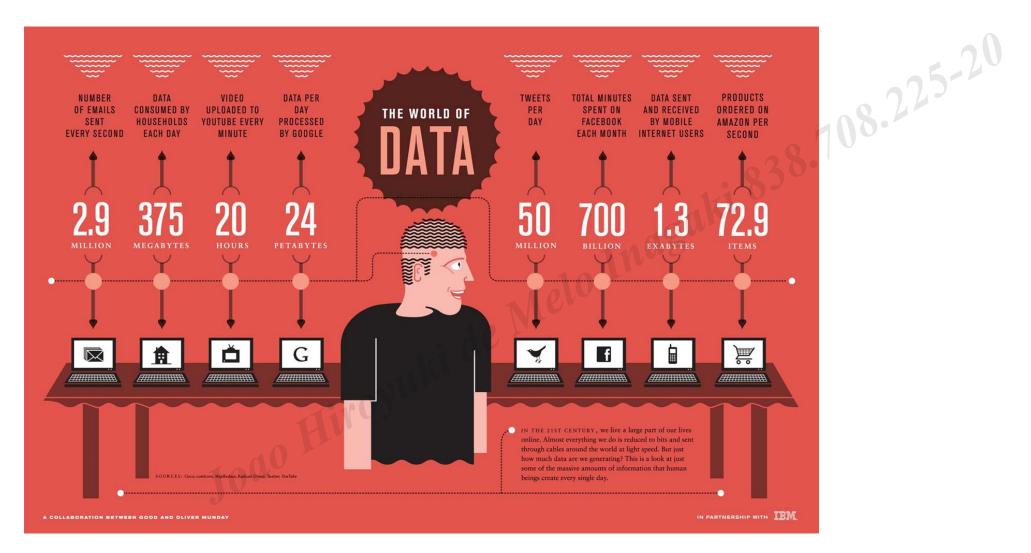


Alguns problemas encontrados...

- E se nosso banco de dados crescer?
- 2. E se tivermos vários bancos de dados?
- 3. E se novos dados chegarem ao longo do tempo?



O nosso mundo de dados

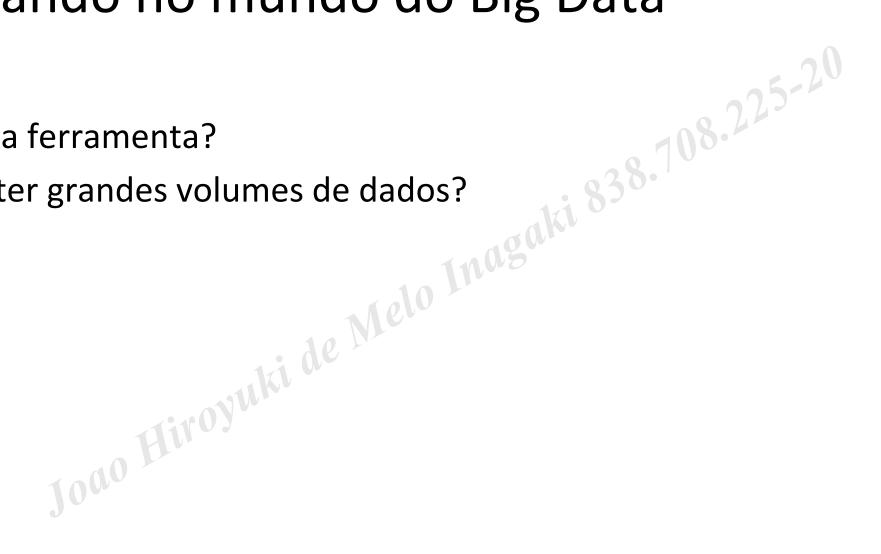


Fonte: https://hexanika.com/history-of-big-data/

MBAUSP

Entrando no mundo do Big Data

- É uma ferramenta?
- É só ter grandes volumes de dados?

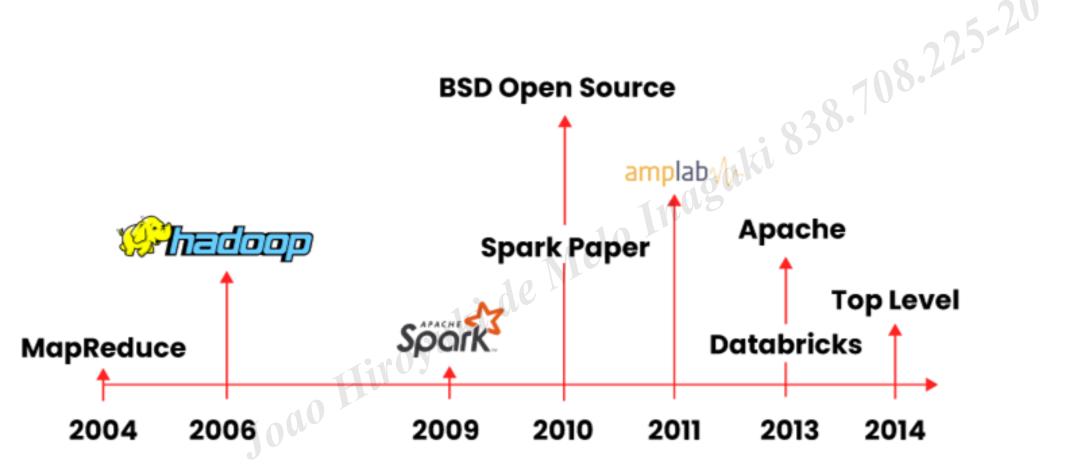


Big Data: Os 5V



Fonte: https://www.cortex-intelligence.com/blog/os-5-vs-do-big-data

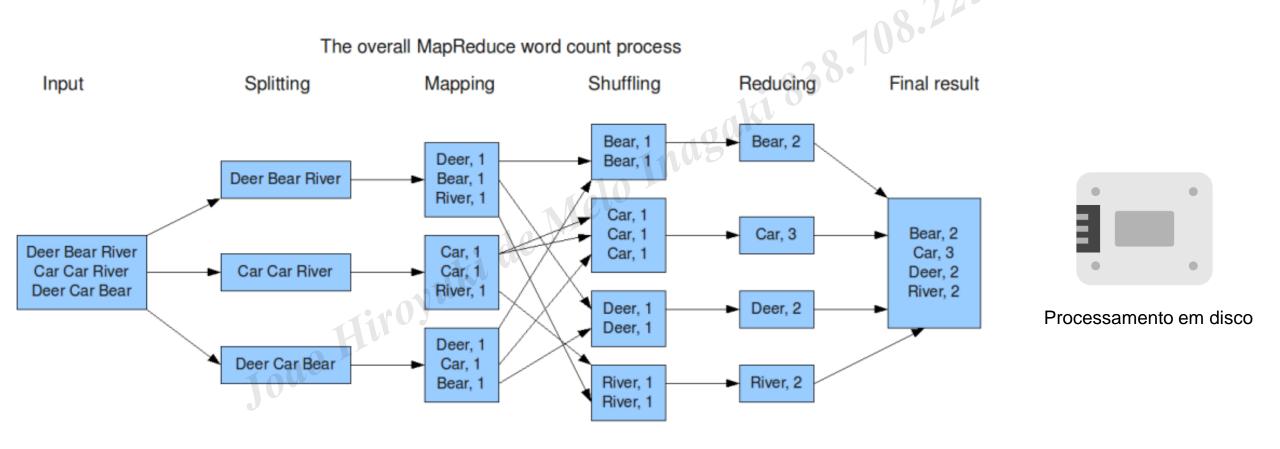
Sua história e evolução



Fonte: https://betravingknows.com/weekly-reports/data-analytics/2018/05/how-big-data-shaped-todays-casino-and-why-you-should-care/



Hadoop e a introdução do MapReduce

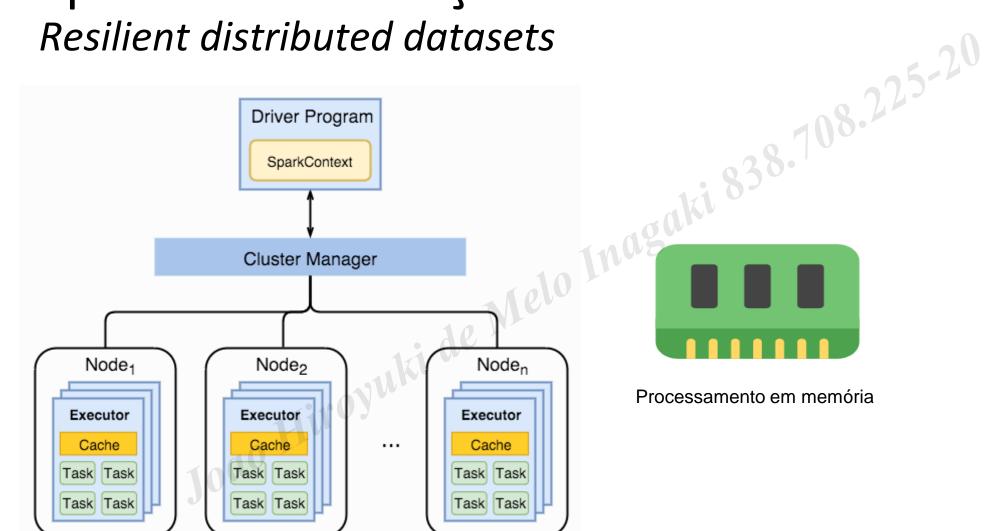


Fonte: https://betravingknows.com/weekly-reports/data-analytics/2018/05/how-big-data-shaped-todays-casino-and-why-you-should-care/



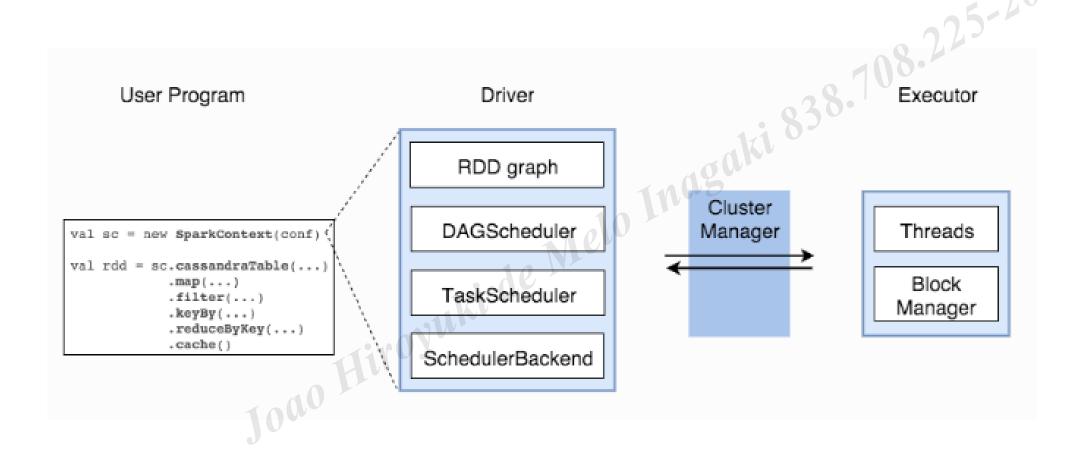
Spark e a introdução do RDD

Resilient distributed datasets



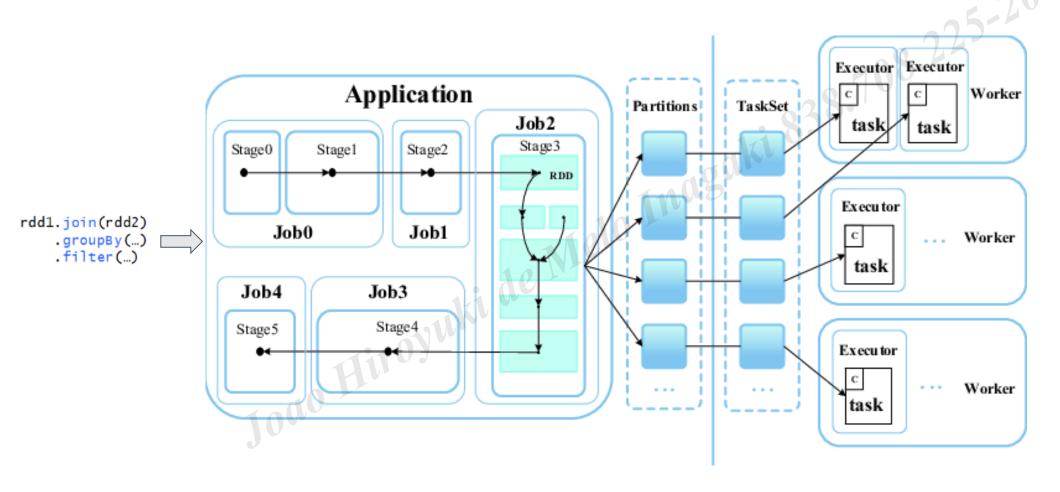


Spark e a introdução do RDD



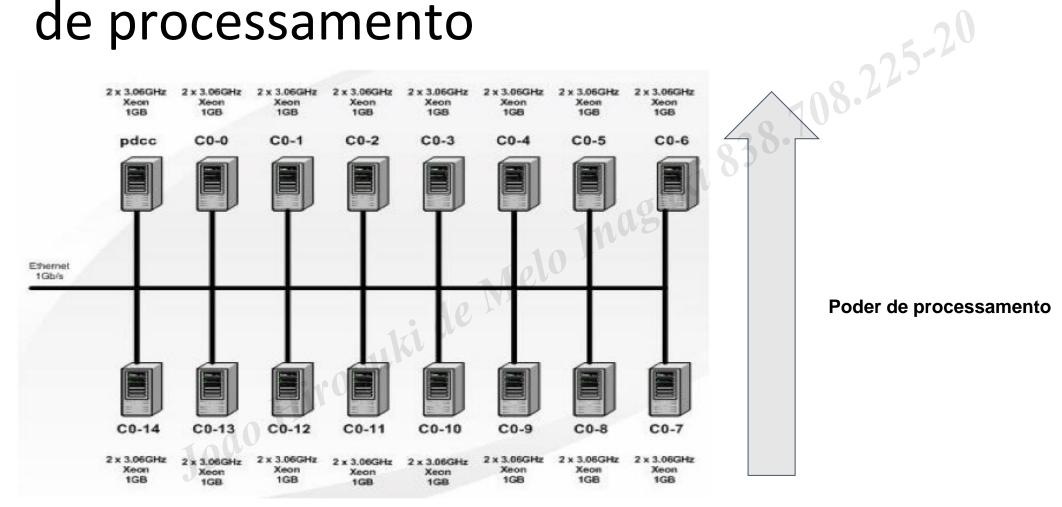


Spark e a introdução do RDD

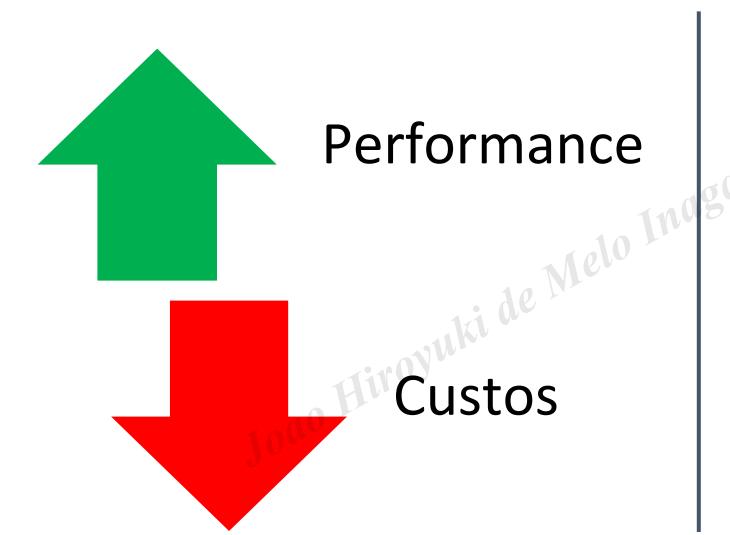




Possibilidade de criar cluster de processamento



Estratégias e boas práticas



- 1. Usar um framework de big data
- 2. Comprimir os dados
- 3. Particionar os dados



Pensar na compressão de dados





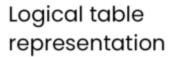
... Até 87% de redução de tamanho

... Até 34x mais rápido para carregar os dados

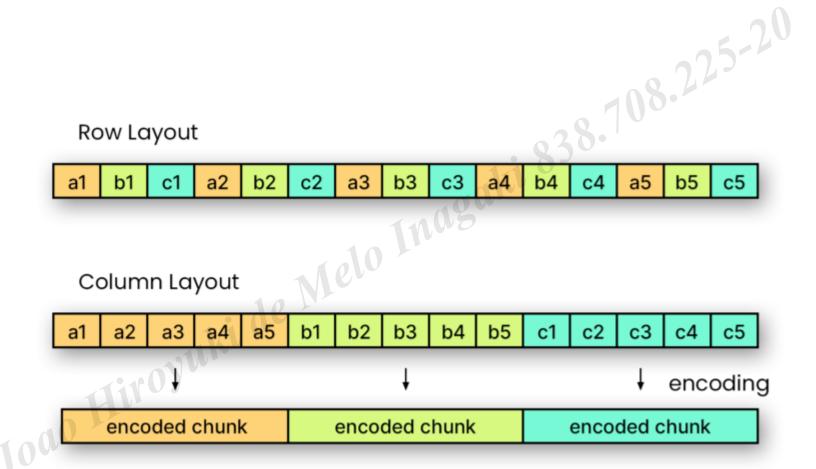
... Até 99% de redução de custos

Fonte: https://www.databricks.com/glossary/what-is-parquet

Como ele funciona?



| а | b | С | |
|----|----|----|--|
| a1 | b1 | c1 | |
| a2 | b2 | c2 | |
| а3 | b3 | сЗ | |
| a4 | b4 | с4 | |
| a5 | b5 | с5 | |



Fonte: https://www.dremio.com/resources/guides/intro-apache-parquet/



Comprime mesmo?

| | | . 838.708.225-20 | | |
|---------------------------------------|-----------------------|------------------|-----------------------|---------------|
| Dataset | Size on Amazon S3 | Query Run time | Data Scanned | Cost |
| Data stored as CSV files | 1 TB | 236 seconds | 1.15 TB | \$5.75 |
| Data stored in Apache Parquet format* | 130 GB | 6.78 seconds | 2.51 GB | \$0.01 |
| Savings / Speedup | 87% less with Parquet | 34x faster | 99% less data scanned | 99.7% savings |

Fonte: https://blog.openbridge.com/how-to-be-a-hero-with-powerful-parquet-google-and-amazon-f2ae0f35ee04

Particionar os dados

Tempo **Q** consulta .../tabela_de_vendas/

.../tabela_de_vendas/ano=2022

.../tabela_de_vendas/ano=2022/mes=8

Drasticamente!!!!

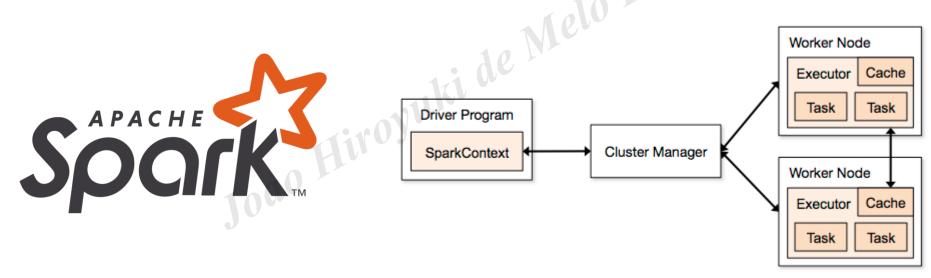
... E em 15 anos?



Framework que iremos utilizar

Spark

- Processamento distribuído em memória
- Ferramenta open source
- Possui biblioteca built-in de Machine Learning



Fonte: https://spark.apache.org/docs/1.1.0/cluster-overview.html



Mãos à obra!







OBRIGADO! 838.708.225-20

linkedin.com/in/helderprado

